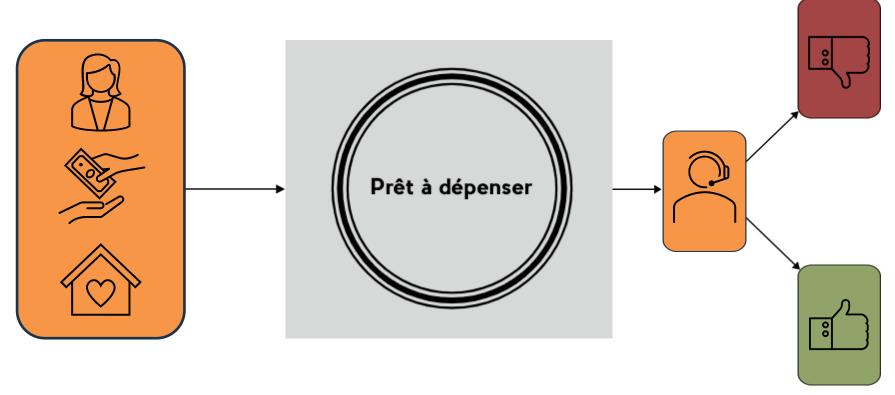
Soutenance du 16 octobre 2023 Yann Pham-Van

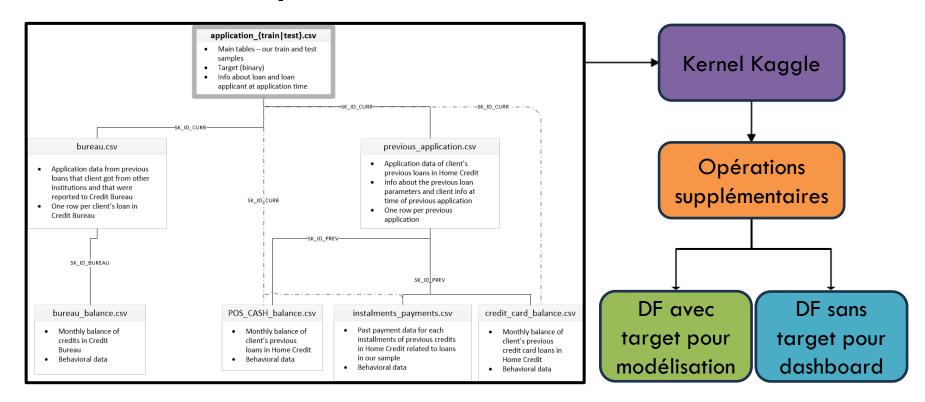
- Problématique
- Modélisation
- Déploiement
- Data drift
- Dashboard

- Problématique
- Modélisation
- Déploiement
- Data drift
- Dashboard

Problématique

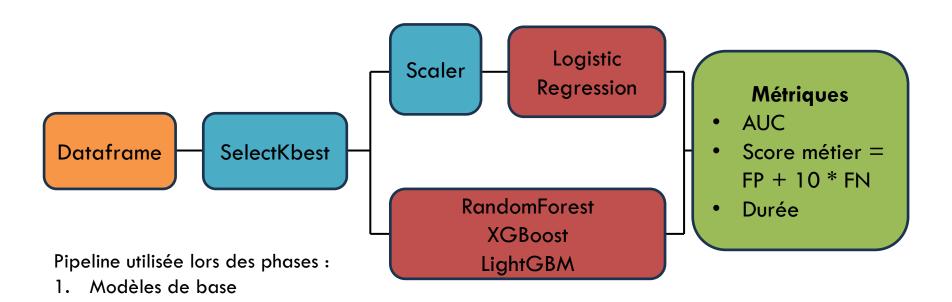


Problématique > dataset



- Problématique
- Modélisation
- Déploiement
- Data drift
- Dashboard

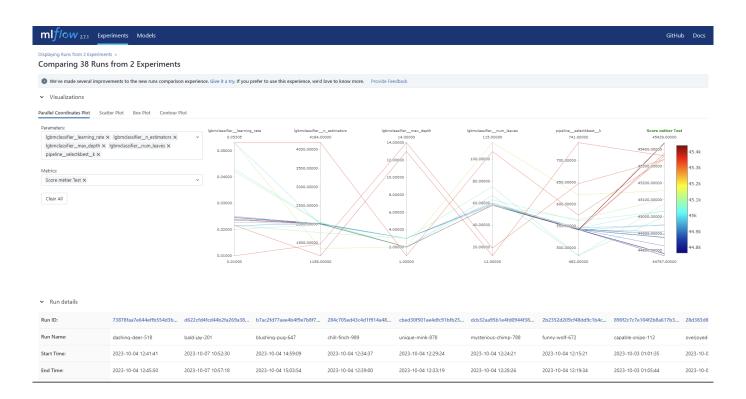
Modélisation > démarche, métriques



Recherche hyperparamètres Optimisation modèle retenu Optimisation seuil de décision

7

Modélisation > MLFlow

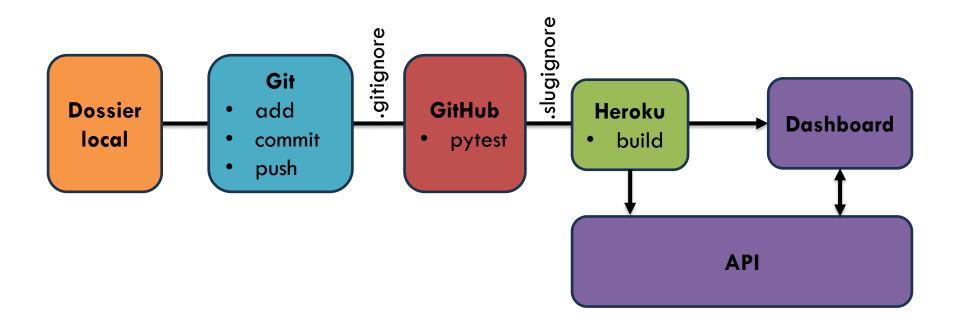


Modélisation > résultats

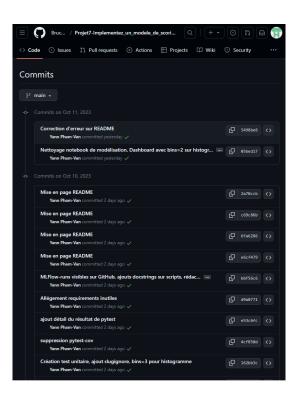
	Phase 1 : modèles de base						Phase 2 : GridSearchCV				Ph. 4
Modèle	DummyClassifier	RandomForest	LogisticRegression	XGBoost	LightGBM	RandomForest	LogisticRegression	XGBoost	LightGBM	LightGBM RandomSearchCV	LightGBM avec threshold optimisé
AUC	0,5	0,723	0,772	0,766	0,781	0,732	0,773	0,774	0,777	0,785	
Score métier	73290	73202	46421	48016	45502	51724	46175	46829	46083	44767	44705
Durée (s)		48	30	98	27						

- Problématique
- Modélisation
- Déploiement
- Data drift
- Dashboard

Déploiement > pipeline

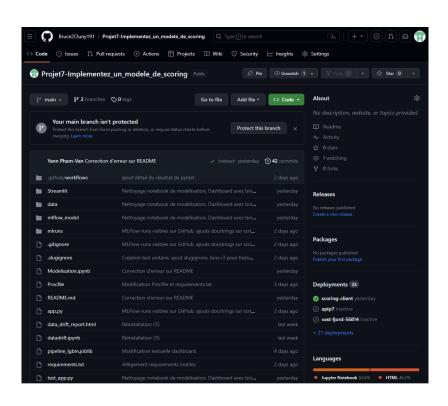


Déploiement > commits



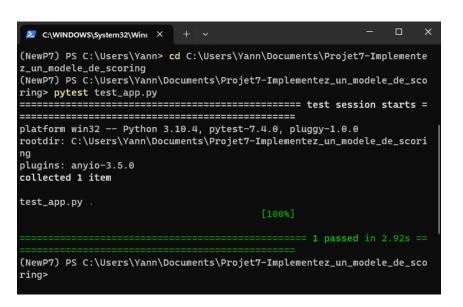
- 42 commits
- Répartis sur 6 semaines

Déploiement > GitHub



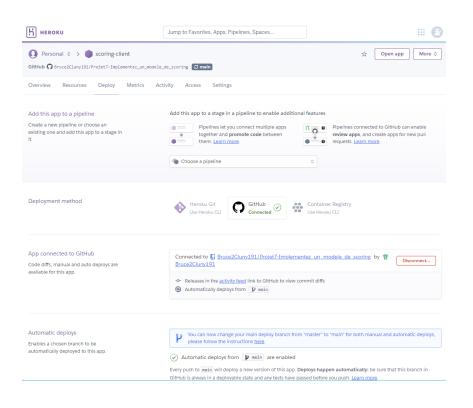
- 1 repository principal
- 1 repository secondaire
 → déploiement du
 dashboard à part

Déploiement > test unitaire



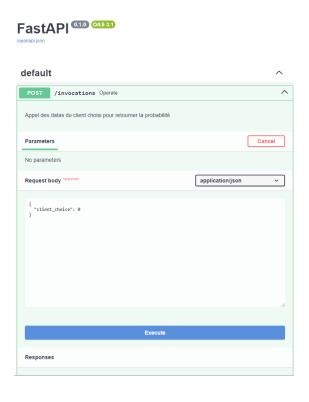
- Pytest
- Vérification que la structure des datas d'un client correspond aux attentes du modèle

Déploiement > Heroku



- 1 app API
- 1 app dashboard
- Déploiement automatique depuis GitHub

Déploiement > API



Quelques clients à tester :

- -275922
- -178317
- -103516
- -251956
- -115290
- -122215

- Problématique
- Modélisation
- Déploiement
- Data drift
- Dashboard

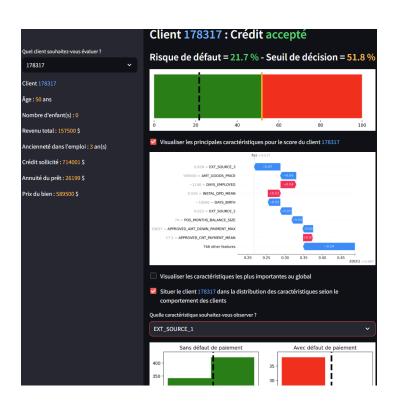
Data drift



- 9 variables drift > 10%
- Global 7,438% < 50%
 → Pas de drift
- 3 variables parmi les plus importantes à surveiller

- Problématique
- Modélisation
- Déploiement
- Data drift
- Dashboard

Dashboard



- Critères d'accessibilité du WCAG
- Jauge d'acceptation avec situation relative du client
- Principales explications du score
- Position du client dans la distribution des variables selon la classification

Avez-vous des questions ?